


EJERCICIOS CONCEPTUALES

Aprendizaje Estadístico



Agustín Musanti

24/06/2026

¿Cuáles son las ventajas y desventajas de un enfoque muy flexible (versus uno menos flexible) para regresión o clasificación? ¿Bajo qué circunstancias podría preferirse un enfoque más flexible a uno menos flexible? ¿Cuándo podría preferirse un enfoque menos flexible?

Ventajas de un método flexible:

- Captura relaciones complejas y no lineales que un modelo rígido no puede representar.
- Reduce el **sesgo** (bias) ya que se ajusta mejor a la forma real de los datos.

Desventajas de un método flexible:

- Mayor **varianza**, ya que tiende a sobreajustar (overfitting), es decir, modela el ruido y no solo la señal.
- Necesita **más datos** para entrenar bien.
- Es menos **interpretable**.
- Más costoso computacionalmente y con más hiperparámetros que tunear.

Cuándo preferir el más flexible:

- Cuando la relación real entre predictores y respuesta es **compleja / no lineal**.
- Cuando tenés **muchos datos** (n grande), que es lo que controla la varianza.
- Cuando el objetivo es pura **predicción** y no importa interpretar el modelo.

Cuándo preferir el menos flexible:

- Cuando la relación subyacente es **aproximadamente lineal / simple**.
- Cuando tenés **pocos datos** (n chico, p grande).
- Cuando importa la **interpretabilidad** / inferencia (entender *por qué*, no solo predecir).
- Cuando los datos son **muy ruidosos**.

Describí las diferencias entre un enfoque de aprendizaje estadístico paramétrico y uno no paramétrico. ¿Cuáles son las ventajas de un enfoque paramétrico para regresión o clasificación (en contraposición a uno no paramétrico)? ¿Cuáles son sus desventajas?

La diferencia central está en si asumo o no una forma funcional para f de antemano.

En un **enfoque paramétrico**, primero asumo una forma para la función f (por ejemplo, que es lineal: $f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$) y después uso los datos solo para estimar ese conjunto fijo de parámetros (los β). Reduzco el problema de "estimar una función entera" a "estimar unos pocos números".

En un **enfoque no paramétrico**, no asumo ninguna forma específica para f . Dejo que sean los datos los que determinen su forma, buscando una función que se acerque a los puntos sin imponerle una estructura previa. KNN, que vengo estudiando, es un buen ejemplo: no asume linealidad ni nada parecido.

Ventajas del paramétrico:

- Es más **simple**: solo tengo que estimar un número acotado de parámetros en lugar de una función arbitraria.
- Necesito **menos datos** para entrenarlo bien.
- Suele ser más **interpretable**: puedo leer directamente qué efecto tiene cada variable (útil cuando me interesa la inferencia, no solo predecir).
- Es más rápido y menos costoso computacionalmente.

Desventajas del paramétrico:

- Mi estimación es tan buena como la **suposición** que hice. Si elijo una forma que no se ajusta a la verdadera f , el modelo va a funcionar mal (sesgo alto).
- Si para compensar uso modelos más flexibles (más parámetros), corro el riesgo de **sobreajustar** (overfitting) y modelar el ruido.

La tabla de abajo muestra un conjunto de entrenamiento con seis observaciones, tres predictores y una variable respuesta cualitativa.

Obs.	X_1	X_2	X_3	Y
1	0	3	0	Red
2	2	0	0	Red
3	0	1	3	Red
4	0	1	2	Green
5	-1	0	1	Green
6	1	1	1	Red

Supongamos que queremos usar este conjunto para predecir Y cuando $X_1 = X_2 = X_3 = 0$ usando K-nearest neighbors.

(a) Calculá la distancia euclidiana entre cada observación y el punto de test (0,0,0).

(b) ¿Cuál es la predicción con $K=1$? ¿Por qué?

(c) ¿Cuál es la predicción con $K=3$? ¿Por qué?

(d) Si la frontera de decisión de Bayes en este problema es altamente no lineal, ¿esperaríamos que el mejor valor de K sea grande o chico? ¿Por qué?

a- La distancia es $\sqrt{(X_1^2 + X_2^2 + X_3^2)}$:

Obs	Cálculo	Distancia	Y
1	$\sqrt{(0+9+0)}$	3.00	Red
2	$\sqrt{(4+0+0)}$	2.00	Red
3	$\sqrt{(0+1+9)} = \sqrt{10}$	≈ 3.16	Red
4	$\sqrt{(0+1+4)} = \sqrt{5}$	≈ 2.24	Green
5	$\sqrt{(1+0+1)} = \sqrt{2}$	≈ 1.41	Green
6	$\sqrt{(1+1+1)} = \sqrt{3}$	≈ 1.73	Red

(b) Predicción con $K=1$

Con $K=1$ miro solo al vecino más cercano. El más cercano es la **Obs. 5** (distancia $\sqrt{2} \approx 1.41$), que es **Green**. Como es el único voto, predigo Green.

(c) Predicción con $K=3$

Con $K=3$ miro a los tres más cercanos:

- Obs. 5 $\rightarrow \sqrt{2} \approx 1.41 \rightarrow$ **Green**
- Obs. 6 $\rightarrow \sqrt{3} \approx 1.73 \rightarrow$ **Red**
- Obs. 2 $\rightarrow 2.00 \rightarrow$ **Red**

Votación: 2 Red vs. 1 Green $\rightarrow$ gano **Red** por mayoría. La probabilidad estimada es 2/3 para Red y 1/3 para Green.

(d) Frontera de Bayes altamente no lineal

Esperaría un **K chico**. Un K chico hace al modelo más flexible: la frontera de decisión de KNN se vuelve más ondulada y se adapta a relaciones no lineales. A medida que K crece, la frontera se va suavizando y tiende a ser casi lineal, así que un K grande no podría capturar una frontera altamente no lineal (tendría sesgo alto). Es el mismo trade-off de antes, ya que para captar no linealidad necesito flexibilidad, y eso viene de un K bajo.